1. Wprowadzenie.

Celem niniejszej analizy jest oszacowanie i przewidzenie trendów cen mieszkań w Warszawie, ze szczególnym uwzględnieniem zmian średniej ceny za metr kwadratowy w krótkim horyzoncie czasowym. Analiza ma wspierać decyzje biznesowe, takie jak ocena ryzyka kredytowego czy wartości zabezpieczeń na rynku nieruchomości.
Warszawa jest największym miastem w Polsce, a jej rynek mieszkaniowy charakteryzuje się dużą dynamiką cen, różnorodnością typów mieszkań oraz wyraźnym wpływem lokalizacji na wartość nieruchomości. Istotne czynniki wpływające na ceny to m.in. odległość od centrum, dostępność infrastruktury miejskiej, rok budowy, powierzchnia oraz liczba pokoi. Rynek ten jest również wrażliwy na zmiany popytu i podaży oraz na czynniki makroekonomiczne, co sprawia, że analiza trendów cen jest kluczowa dla instytucji finansowych.
Do analizy wykorzystano dane dotyczące sprzedaży mieszkań w Warszawie z publicznego zbioru Apartment Prices in Poland dostępnego na platformie Kaggle: https://www.kaggle.com/datasets/krzysztofjamroz/apartmentprices-in-poland. Dane obejmują okres od sierpnia 2023 do czerwca 2024 i zawierają informacje o lokalizacji, parametrach nieruchomości oraz cenach transakcyjnych.

2. Analiza eksploracyjna.

2.1. Zakres i struktura danych

Analizie poddano dane dotyczące sprzedaży oraz wynajmu mieszkań w Warszawie w okresie od sierpnia 2023 do czerwca 2024.

Po przefiltrowaniu zbioru do miasta Warszawa:

- Sprzedaż: 59 246 obserwacji (przed czyszczeniem)
- Wynajem: 28 414 obserwacji (przed czyszczeniem)

Dane obejmują informacje dotyczące:

- powierzchni mieszkania (squareMeters),
- liczby pokoi (rooms),
- piętra i liczby pięter w budynku,
- roku budowy,
- odległości od centrum,
- liczby punktów usługowych (poiCount),
- odległości od szkół, przedszkoli, aptek itd.,
- ceny ofertowej.

Zakres czasowy umożliwia analizę krótkookresowych trendów cenowych.

2.2. Braki danych

W zbiorze występowały braki danych, szczególnie w zmiennych:

- condition,
- buildingMaterial,
- buildYear,
- floor.

Ze względu na duży udział braków w zmiennych jakościowych (np. condition), nie zostały one wykorzystane w modelu hedonicznym. Do modelowania wybrano zmienne o relatywnie wysokiej kompletności danych.
W analizie zastosowano podejście polegające na usunięciu obserwacji z brakami w kluczowych zmiennych wykorzystywanych w modelu.

2.3. Statystyki opisowe - sprzedaż

Po wstępnym oczyszczeniu danych:

- Usunięto mieszkania o powierzchni poniżej 15 m².
- Usunięto obserwacje z dolnego i górnego 1% rozkładu ceny za m² (eliminacja outlierów).

Liczba obserwacji po czyszczeniu: 58 058.

Podstawowe statystyki dla ceny za m² (sprzedaż):

- Średnia: ok. 17 333 zł/m²
- Mediana: ok. 16 900 zł/m²
- 25 percentyl: ok. 14 286 zł/m²
- 75 percentyl: ok. 19 832 zł/m²
- Maksimum (po czyszczeniu): ok. 31 000 zł/m²

Średnia powierzchnia mieszkania wynosi ok. 60 m², a mediana liczby pokoi to 3.
Rozkład ceny za m² jest prawostronnie skośny, co uzasadnia zastosowanie logarytmicznej transformacji w modelu regresji.

2.4. Statystyki opisowe - wynajem

Po analogicznym oczyszczeniu danych dla rynku wynajmu:

- Liczba obserwacji: 27 787
- Średnia cena najmu za m²: ok. 84,6 zł/m²
- Mediana: ok. 80 zł/m²
- 25 percentyl: ok. 67,7 zł/m²
- 75 percentyl: ok. 96 zł/m²

Rynek wynajmu wykazuje mniejszą zmienność względną niż rynek sprzedaży, jednak również charakteryzuje się prawostronną skośnością rozkładu cen.

2.5. Trend cen sprzedaży w czasie

Średnia cena za m² w Warszawie wykazuje wyraźny trend wzrostowy:

- Sierpień 2023: ok. 15 538 zł/m²
- Czerwiec 2024: ok. 18 312 zł/m²

Oznacza to wzrost o około 18% w analizowanym okresie.
Trend jest systematyczny, choć w ostatnich miesiącach widoczne jest spłaszczenie dynamiki wzrostu.

Wykres 1. Średnia cena za m² -Warszawa (sprzedaż)

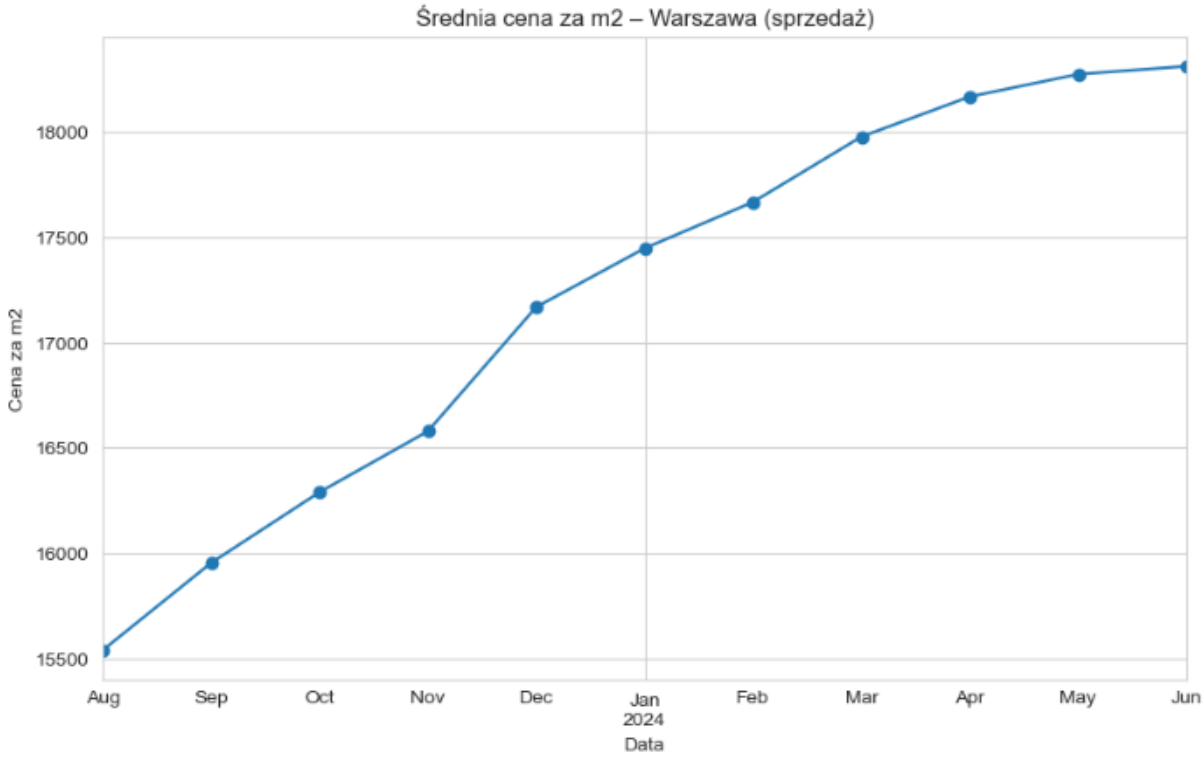

W analizowanym okresie (VIII 2023 - VI 2024) obserwujemy systematyczny i wyraźny wzrost średniej ceny mieszkań za m² w Warszawie.
Cena wzrosła z ok. 15 600 zł/m² w sierpniu 2023 do ponad 18 300 zł/m² w czerwcu 2024, co oznacza wzrost rzędu ok. 17–18% w całym okresie.
Najważniejsze obserwacje:

- Najsilniejsze przyspieszenie wzrostu nastąpiło w IV kwartale 2023 r.
- Od marca 2024 dynamika wzrostu zaczyna wyraźnie słabnąć.
- W maju i czerwcu 2024 tempo wzrostu jest już niewielkie, co może wskazywać na przechodzenie rynku w fazę stabilizacji.

Wykres potwierdza, że analizowany okres był fazą silnego ożywienia cenowego, jednak końcówka próby sugeruje wygaszanie presji wzrostowej.

Wzrost cen może wynikać z:

- ograniczonej podaży,
- wysokiego popytu inwestycyjnego,
- poprawy dostępności kredytów w analizowanym okresie.

2.6. Trend cen wynajmu

Wykres 2. Średnia cena wynajmu za m² - Warszawa

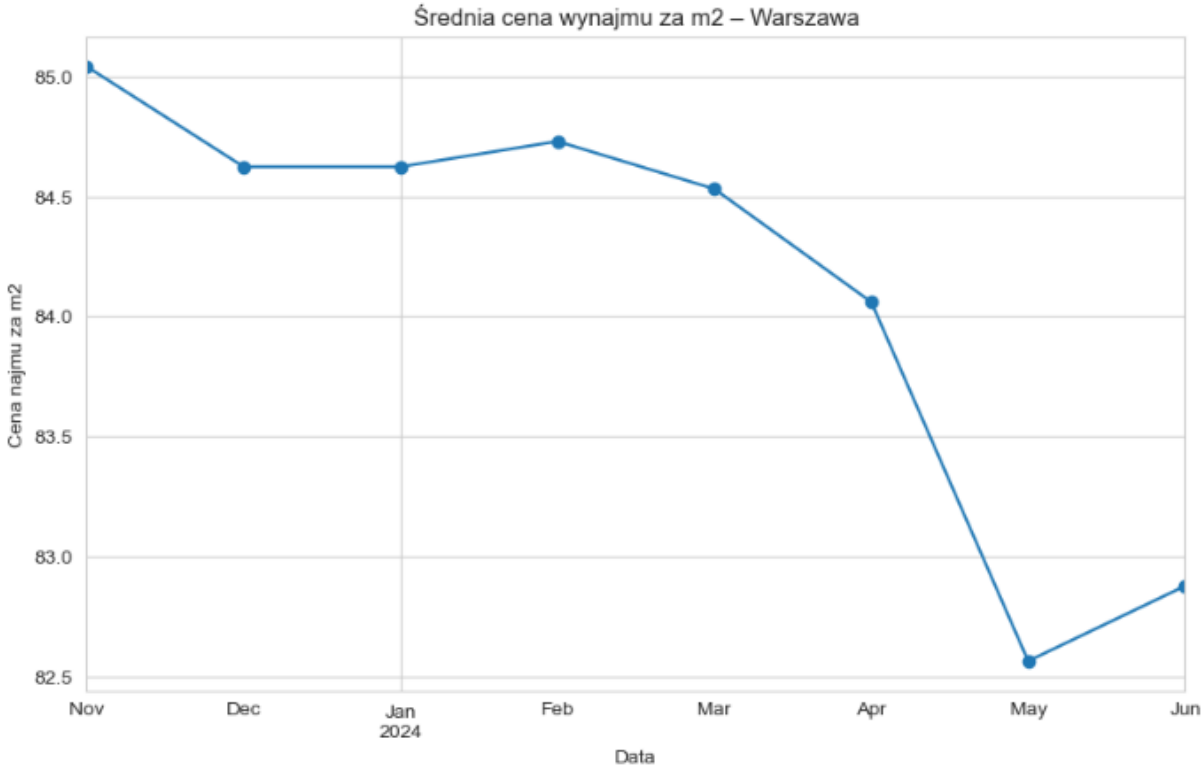

W przeciwieństwie do rynku sprzedaży, rynek wynajmu wykazuje znacznie większą stabilność cenową.

W okresie listopad 2023 – czerwiec 2024 ceny wynajmu za m²:

- początkowo lekko spadają (XI–XII),
- stabilizują się w styczniu–lutym,
- następnie wyraźnie obniżają się w kwietniu i maju,
- w czerwcu obserwujemy niewielkie odbicie.

Ogólnie poziom cen wynajmu waha się w przedziale 82,5–85 zł/m², co oznacza relatywnie niewielkie zmiany w porównaniu z dynamicznym wzrostem cen sprzedaży.

Interpretacja ekonomiczna:

- rynek wynajmu nie podąża za wzrostem cen mieszkań,
- możliwe jest osiągnięcie bariery popytowej (ograniczona zdolność najemców do akceptowania wyższych czynszów),
- wiosenny spadek może być efektem sezonowości.

Rynek najmu w analizowanym okresie jest zdecydowanie bardziej stabilny niż rynek sprzedaży.

W przeciwieństwie do rynku sprzedaży, rynek wynajmu wykazuje niewielką korektę:

- Zmiana w analizowanym okresie: -2,54%

Oznacza to względną stabilizację lub lekkie osłabienie rynku najmu przy jednoczesnym wzroście cen sprzedaży.

2.7. Relacja czynsz/cena

Obliczono relację:

$$\frac{12 \times czynsz}{cena}$$

Wyniki:

- Listopad 2023: ok. 6,15%
- Czerwiec 2024: ok. 5,43%

Spadek wskaźnika oznacza, że ceny mieszkań rosły szybciej niż czynsze.

Może to sugerować:

- spadek rentowności inwestycji mieszkaniowych,
- wzrost cen napędzany oczekiwaniami kapitałowymi,
- potencjalne przegrzewanie rynku w segmencie zakupów inwestycyjnych.

Z perspektywy banku oznacza to:

- wzrost wartości zabezpieczeń,
- ale jednocześnie spadek atrakcyjności inwestycyjnej nieruchomości jako źródła dochodu z wynajmu.

Wykres 3. Stosunek ceny wynajmu do ceny sprzedaży (roczna stopa brutto)

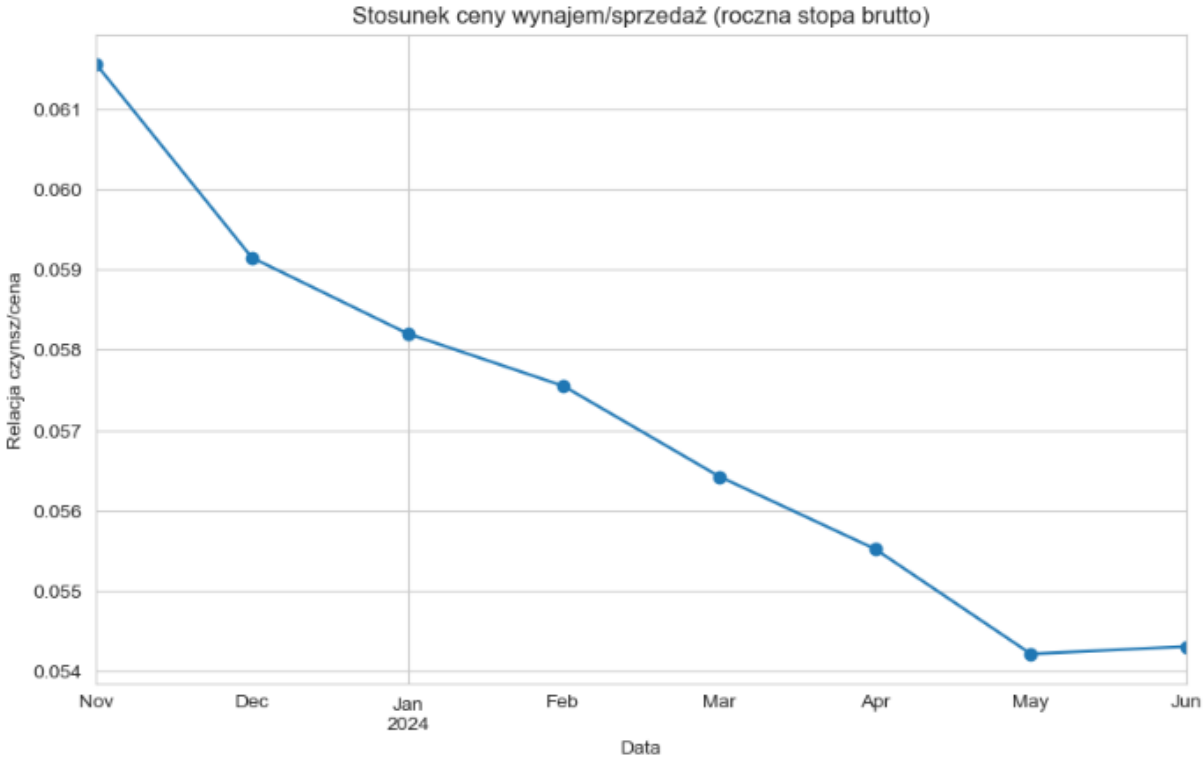

Wykres przedstawia tzw. rent-to-price ratio, czyli roczną stopę zwrotu brutto z wynajmu.
W analizowanym okresie wskaźnik ten systematycznie maleje z poziomu ok. 6,1% w listopadzie 2023 do ok. 5,4% w maju–czerwcu 2024.

Oznacza to, że:

- ceny mieszkań rosną szybciej niż czynsze,
- rentowność inwestycji w mieszkania spada,
- inwestycje mieszkaniowe stają się relatywnie mniej atrakcyjne dochodowo.

Spadek rentowności może sugerować:

- przewagę popytu inwestycyjnego nad fundamentami dochodowymi,
- stopniowe „przegrzewanie” rynku sprzedaży względem rynku wynajmu.

2.8. Wnioski z analizy eksploracyjnej

Rynek sprzedaży mieszkań w Warszawie wykazuje silny, systematyczny wzrost cen.
Rynek wynajmu pozostaje względnie stabilny lub lekko malejący.
Spada rentowność inwestycyjna mieszkań.

Ceny silnie zależą od:

- odległości od centrum,

- roku budowy,
- liczby punktów usługowych,
- struktury mieszkania.

Wnioski te uzasadniają zastosowanie modelu hedonicznego w celu oddzielenia efektu jakości mieszkań od rzeczywistego efektu czasowego oraz budowę indeksu cen nieruchomości.

3. Przygotowanie danych

3.1. Integracja danych miesięcznych

Dane źródłowe były zapisane w osobnych plikach CSV dla poszczególnych miesięcy (np. apartments_pl_2023_08.csv).

W pierwszym kroku:

- wczytano wszystkie pliki sprzedaży,
- wyodrębniono z nazw plików informacje o roku i miesiącu,
- utworzono zmienną date jako pierwszy dzień danego miesiąca,
- połączono wszystkie pliki w jeden zbiór danych.

Analogicznie przygotowano dane dla rynku wynajmu.

3.2. Wybór miasta

Zgodnie z wymaganiami zadania wybrano jedno miasto - Warszawę - jako obiekt szczegółowej analizy.

Filtrowanie wykonano na podstawie zmiennej city, uzyskując:

- 59 246 obserwacji sprzedaży,
- 28 414 obserwacji najmu (przed czyszczeniem).

Warszawa została wybrana ze względu na:

- największą liczbę obserwacji,
- wysoką dynamikę rynku,
- duże znaczenie ekonomiczne w skali kraju.

3.3. Konstrukcja zmiennej cena za m²

Ponieważ ceny mieszkań silnie zależą od powierzchni, zamiast analizować cenę całkowitą, skonstruowano zmienną:

$$price_per_m2 = \frac{price}{squerMeters}$$

Umożliwia to:

- porównywanie mieszkań o różnej wielkości,
- analizę czystej wyceny jednostkowej,
- budowę indeksu cen nieruchomości.

3.4. Czyszczenie danych (Eliminacja obserwacji skrajnych)

W celu poprawy jakości estymacji modelu usunięto:

- mieszkania o powierzchni poniżej 15 m² (potencjalne błędy danych),
- obserwacje należące do dolnego 1% oraz górnego 1% rozkładu ceny za m².

Zastosowanie filtrów kwantylowych ogranicza wpływ:

- błędnie wprowadzonych cen,
- luksusowych, niereprezentatywnych nieruchomości,
- obserwacji o nietypowych parametrach.

Po czyszczeniu liczba obserwacji wyniosła:

- 58 058 (sprzedaż),
- 27 787 (wynajem).

3.5. Wybór zmiennych do modelowania

W modelu hedonicznym wykorzystano zmienne:

- squareMeters - powierzchnia mieszkania,
- rooms - liczba pokoi,
- floor - piętro,
- floorCount - liczba pięter w budynku,
- buildYear - rok budowy,
- centreDistance - odległość od centrum,
- poiCount - liczba punktów usługowych w pobliżu.

Zmiennych takich jak condition i buildingMaterial nie wykorzystano ze względu na dużą liczbę braków danych.
Obserwacje zawierające braki w wybranych zmiennych zostały usunięte przed estymacją modelu.

3.6. Transformacja zmiennej zależnej

W celu:

- redukcji skośności rozkładu,

- stabilizacji wariancji,
- umożliwienia interpretacji parametrów jako zmian procentowych,
- zastosowano transformację logarytmiczną:

$$\log_price_m2 = \ln(price_per_m2)$$

3.7. Konstrukcja efektów czasowych

Aby oddzielić wpływ cech mieszkań od czystego efektu czasu, utworzono zmienne zero-jedynkowe dla poszczególnych miesięcy (dummy variables).
Pierwszy miesiąc (sierpień 2023) przyjęto jako okres bazowy.

Współczynniki przy zmiennych miesięcznych interpretowane są jako:

- procentowa zmiana ceny mieszkań względem miesiąca bazowego, po kontrolowaniu za jakość nieruchomości.

Na podstawie tych współczynników skonstruowano hedoniczny indeks cen mieszkań.

3.8. Standaryzacja zmiennych (stabilność estymacji)

Ze względu na różne skale zmiennych (np. rok budowy vs. liczba pokoi) zastosowano standaryzację zmiennych ciągłych przed estymacją modelu.
Celem było:

- zmniejszenie problemu współliniowości,
- poprawa stabilności numerycznej estymacji,
- redukcja wysokiej wartości condition number.

Standaryzacja nie wpływa na interpretację efektów czasowych, które pozostają kluczowe dla konstrukcji indeksu.

3.9. Podsumowanie przygotowania danych

Proces przygotowania danych obejmował:

- Integrację miesięcznych plików CSV.
- Filtrowanie do miasta Warszawa.
- Konstrukcję ceny za m².
- Eliminację obserwacji skrajnych.
- Selekcję zmiennych o wysokiej jakości danych.
- Transformację logarytmiczną ceny.
- Konstrukcję efektów czasowych.
- Standaryzację zmiennych numerycznych.

Tak przygotowany zbiór danych stanowi podstawę do estymacji modelu hedonicznego oraz budowy indeksu cen mieszkań, który następnie wykorzystano do prognozowania krótkookresowych trendów cenowych.

4. Model hedoniczny

4.1. Cel modelu

Celem estymacji modelu hedonicznego było:

- oszacowanie wpływu cech mieszkań na cenę za m²,
- oddzielenie efektu jakości nieruchomości od efektu czasu,
- konstrukcja indeksu cen mieszkań w Warszawie,
- przygotowanie podstawy do analizy trendu i prognozowania.

Model został oszacowany metodą klasycznej regresji liniowej (OLS).

4.2. Specyfikacja modelu

Zmienną zależną była:

$$\log\ _price_m2 = \ln\ (price_per_m2)$$

Specyfikacja modelu:

$$\ln(price_{it}) - \beta_0 + \beta_1 squareMeters_{it} + \beta_2 rooms_{it} + \beta_3 floor_{it} + \beta_4 floorCount_{it} + \beta_5 buildYear_{it} + \beta_6 centreDistance_{it} + \beta_7 pointCount_{it} + \sum_t \gamma_t D_t + \varepsilon_{it}$$

gdzie:

D_t – zmienne zero-jedynkowe dla miesięcy (sierpień 2023 jako baza),

i – mieszkanie,

t – miesiąc.

Liczba obserwacji po czyszczeniu danych: 44 695

Liczba zmiennych objaśniających: 17

4.3. Dopasowanie modelu

Najważniejsze statystyki:

- $R^2 = 0{,}381$
- Adj. $R^2 = 0{,}381$
- F-statistic: 1621 ($p < 0{,}001$)

Oznacza to, że model wyjaśnia około 38% zróżnicowania cen za m².

Model wyjaśnia 38% zróżnicowania cen za m².

Dla rynku nieruchomości jest to wynik typowy - ceny zależą także od czynników trudnych do uchwycenia w danych (standard wykończenia, widok, mikro-lokalizacja, negocjacje).
Durbin-Watson = 1,94 → brak istotnej autokorelacji reszt.
Condition number = 17,3 → brak problemu silnej współliniowości.

4.4. Interpretacja parametrów strukturalnych

Wszystkie zmienne są statystycznie istotne ($p < 0,001$).
Ponieważ zmienna zależna jest w logarytmie, współczynniki można interpretować jako przybliżone zmiany procentowe.

Powierzchnia (squareMeters)

- $\beta = 0,0167$

Większa powierzchnia (po standaryzacji) zwiększa cenę za m².
Oznacza to, że większe mieszkania w Warszawie są przeciętnie wyceniane wyżej jednostkowo.

Liczba pokoi (rooms)

- $\beta = -0,0539$

Przy stałej powierzchni większa liczba pokoi obniża cenę za m².
Mieszkania z większą liczbą mniejszych pomieszczeń są wyceniane niżej niż bardziej przestronne układy.

Piętro (floor)

- $\beta = -0,0041$

Wyższe piętro nieznacznie obniża cenę za m² (po kontrolowaniu innych cech).

Liczba pięter (floorCount)

- $\beta = -0,0146$

Wyższe budynki są przeciętnie powiązane z niższą ceną za m².

Rok budowy (buildYear)

- $\beta = 0,0620$

To jedna z najsilniejszych zmiennych jakościowych.
Nowsze budynki są istotnie droższe - rynek wyraźnie premiuje nowe inwestycje.

Odległość od centrum (centreDistance)

- $\beta = -0,1089$

Najsilniejszy efekt w modelu.
Większa odległość od centrum znacząco obniża cenę za m².

Liczba punktów usługowych (poiCount)

- β = 0,0423

Lepsza infrastruktura lokalna wyraźnie zwiększa wartość nieruchomości.

4.5. Efekty czasowe - konstrukcja indeksu

Sierpień 2023 przyjęto jako okres bazowy (indeks = 100).
Współczynniki miesięczne są dodatnie i rosną w czasie, co wskazuje na systematyczny wzrost cen po kontrolowaniu jakości mieszkań.

Wykres 4. Hedoniczny indeks cen mieszkań - Warszawa

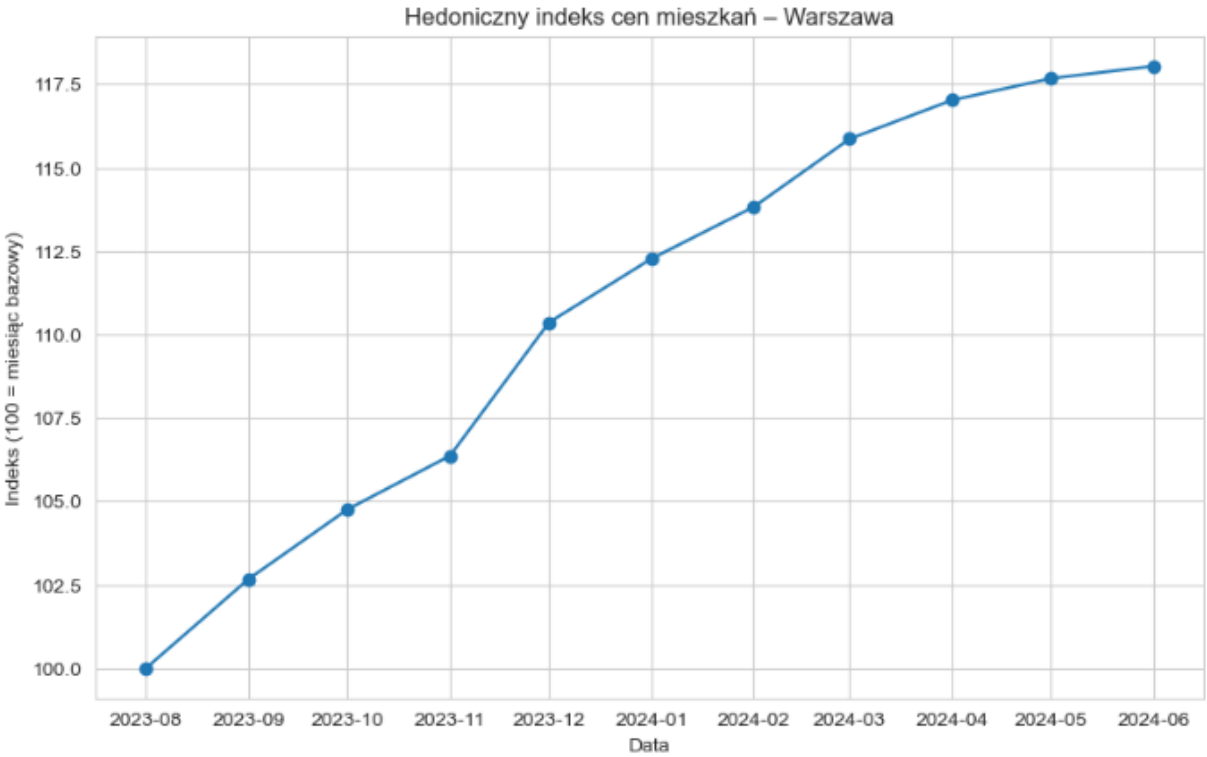

Hedoniczny indeks cen pokazuje zmianę cen mieszkań po skorygowaniu o jakość (metraż, liczbę pokoi, rok budowy, odległość od centrum itd.). Oznacza to, że obserwujemy „czystą" zmianę cen rynkowych, a nie efekt sprzedaży mieszkań o innej strukturze.

Dynamika indeksu

- Miesiąc bazowy (08.2023): 100
- 12.2023: ok. 110
- 03.2024: ok. 116
- 06.2024: ok. 118

Łączny wzrost indeksu wynosi ok. 18% w analizowanym okresie. Średnia cena w sierpniu 2023 wynosiła ok. 15 600 zł/m². Wzrost indeksu do poziomu 118 oznacza, że po oczyszczeniu z efektów jakościowych ceny wzrosły o ok. 18%. Rzeczywiście obserwowana średnia cena w

czerwcu 2024 wynosi ok. 18 300–18 400 zł/m², co potwierdza spójność indeksu z danymi nominalnymi.

Wnioski

- Wzrost cen miał charakter systematyczny i niemal liniowy.
- Najsilniejsze przyspieszenie nastąpiło między listopadem a styczniem.
- Od marca 2024 tempo wzrostu wyraźnie słabnie (mniejsze przyrosty indeksu miesiąc do miesiąca).
- Oznacza to przejście z fazy dynamicznego wzrostu do fazy stabilizacji rynku.

Indeks hedoniczny potwierdza, że wzrost cen nie wynikał wyłącznie ze zmiany struktury sprzedawanych mieszkań, lecz był rzeczywistym wzrostem poziomu cen w Warszawie.

Przykładowe wartości indeksu:

Miesiąc	Indeks (2023-08 = 100)
2023-09	102,7
2023-12	110,4
2024-03	115,9
2024-06	118,0

Oznacza to wzrost cen mieszkań o około 18% w analizowanym okresie, po skorygowaniu o strukturę sprzedawanych nieruchomości.

Wzrost ma charakter:

- silny w IV kwartale 2023,
- kontynuowany w I połowie 2024,
- z widocznym spłaszczeniem dynamiki w końcowych miesiącach.

4.6. Prognoza krótkookresowa (ARIMA)

Na logarytmie indeksu oszacowano model ARIMA(1,1,1).

Wykres 5. Prognoza hedonicznego indeksu cen (ARIMA)

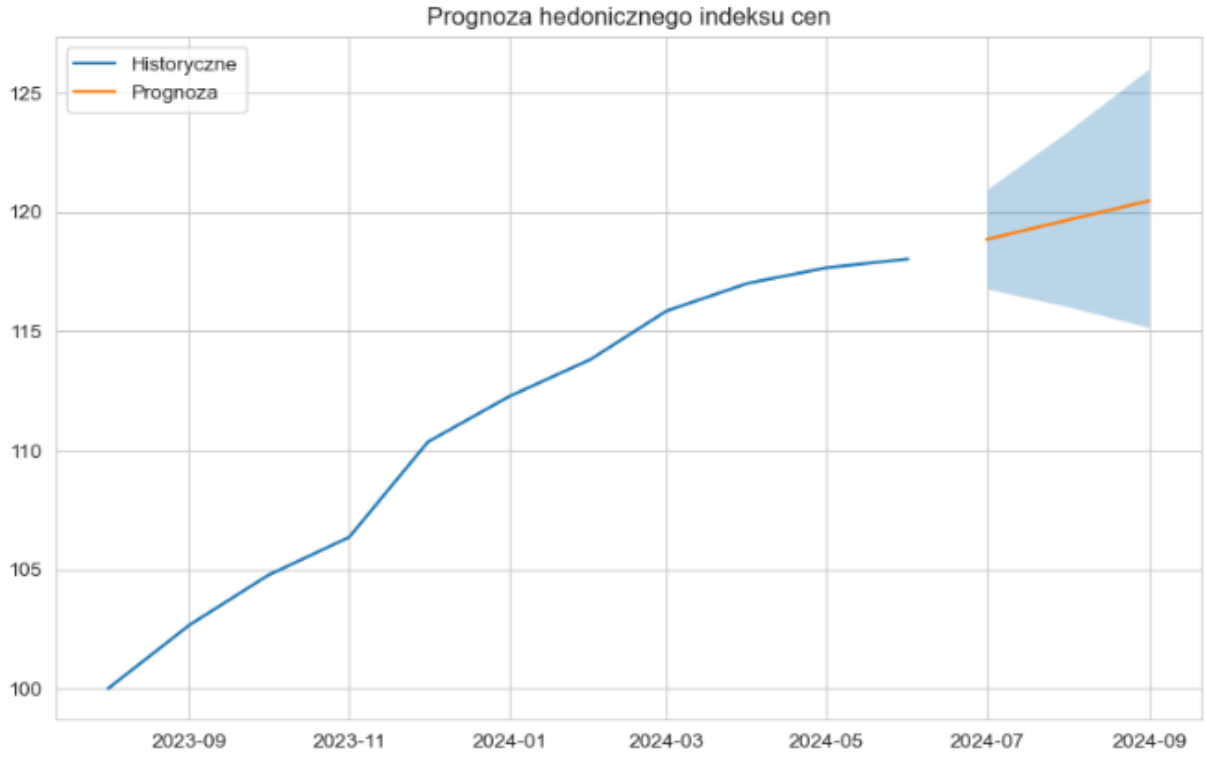

Prognozowana ścieżka indeksu

- Ostatnia obserwacja historyczna (06.2024): ok. 118
- Prognoza na 07-09.2024: wzrost do ok. 120–121

Model wskazuje więc na dalszy, lecz umiarkowany wzrost.

Jeżeli przyjmiemy poziom 18 300–18 400 zł/m² w czerwcu 2024 jako punkt wyjścia:
Wzrost indeksu z 118 do 120 oznacza ok. +1,7%. W scenariuszu centralnym model sugeruje więc wzrost przeciętnej ceny do ok. 18 600–18 800 zł/m² do września 2024.
Przedziały ufności są stosunkowo szerokie, co oznacza niepewność prognozy. W dolnym scenariuszu ceny mogłyby pozostać w pobliżu 18 200–18 300 zł/m², natomiast w górnym scenariuszu mogłyby zbliżyć się nawet do ok. 19 000 zł/m².

Wnioski

- Model nie wskazuje na odwrócenie trendu.
- Prognozowany wzrost jest wyraźnie wolniejszy niż w IV kwartale 2023.
- Rynek przechodzi w fazę stabilizacji z umiarkowaną dodatnią dynamiką.

Z punktu widzenia banku oznacza to niskie ryzyko gwałtownego spadku cen w krótkim okresie, lecz jednocześnie brak przesłanek do dalszej dynamicznej ekspansji cenowej.

Prognoza indeksu:

Miesiąc	Prognozowany indeks
2024-07	118,86

2024-08	119,67
2024-09	120,48

Model wskazuje na:

- dalszy, umiarkowany wzrost cen,
- wyraźne wyhamowanie dynamiki,
- brak sygnałów gwałtownej korekty w krótkim okresie.

Oznacza to przejście rynku z fazy silnej ekspansji do fazy stabilizacji wzrostowej.

4.7. Wnioski z modelu

- Najsilniejszym determinantem cen jest lokalizacja (odległość od centrum).
- Rynek silnie premiuje nowe budownictwo.
- Dostępność infrastruktury lokalnej istotnie zwiększa wartość mieszkań.
- Po kontrolowaniu jakości obserwujemy realny wzrost cen o 18% w analizowanym okresie.
- Prognoza ARIMA wskazuje na dalszy, ale spowolniony wzrost cen w kolejnych miesiącach.

Model jest stabilny statystycznie (niski condition number) i stanowi solidną podstawę do:

- budowy indeksu cen,
- oceny trendów rynkowych,
- przygotowania rekomendacji dla sektora bankowego.

5. Prognozowanie trendu

5.1. Dynamika cen po korekcie jakości

Na podstawie modelu hedonicznego skonstruowano indeks cen mieszkań w Warszawie (sierpień 2023 = 100).

Wartości indeksu:

Miesiąc	Indeks
2023-08	100,00
2023-09	102,67
2023-10	104,76
2023-11	106,36
2023-12	110,36
2024-01	112,27
2024-02	113,82
2024-03	115,86
2024-04	117,02

2024-05	117,67
2024-06	118,04

Łączny wzrost w badanym okresie:

- 18,04%

Interpretacja dynamiki

Można wyróżnić trzy fazy rynku:

- Faza przyspieszenia (IX–XII 2023)
  Silny wzrost, kulminacja w grudniu 2023 (3,76% m/m).
- Faza stabilnego wzrostu (I–III 2024)
  Dynamika w przedziale 1,3–1,8% miesięcznie.
- Faza wyraźnego spowolnienia (IV–VI 2024)
  Spadek dynamiki do:
  - 1,00% (kwiecień),
  - 0,56% (maj),
  - 0,31% (czerwiec).

Oznacza to wyraźne wygasanie presji wzrostowej.

5.2. Prognoza krótkookresowa – model ARIMA

Na logarytmie indeksu oszacowano model ARIMA(1,1,1), co pozwoliło uchwycić krótkookresową dynamikę trendu.

Prognozowane wartości indeksu:

Miesiąc	Prognozowany indeks
2024-07	118,86
2024-08	119,67
2024-09	120,48

Wnioski z prognozy

Model wskazuje na:

- dalszy wzrost cen,
- ale wyraźnie niższą dynamikę niż w IV kwartale 2023,
- brak sygnałów gwałtownej korekty w krótkim okresie.

Szacowany wzrost w III kwartale 2024 ma charakter łagodnego trendu wzrostowego, a nie fazy boomu.

5.3. Przeliczenie wyników na cały okres tempa wzrostu

Łączny wzrost 18,04% w okresie 10 miesięcy oznacza bardzo wysoką roczną dynamikę.

Jednak obserwowane spowolnienie miesięczne sugeruje, że:

- tempo wzrostu z końca 2023 nie jest trwałe,
- rynek wchodzi w fazę normalizacji,
- dalsza dynamika będzie prawdopodobnie jednocyfrowa w ujęciu rocznym.

5.4. Ocena fazy cyklu rynkowego

Na podstawie:

- silnego wzrostu w 2023,
- wygasania dynamiki w 2024,
- stabilnej prognozy ARIMA,
- można stwierdzić, że rynek warszawski przechodzi z fazy ekspansji do fazy stabilizacji po silnym wzroście.

Nie obserwujemy:

- gwałtownego załamania,
- eksplozji bańki cenowej,
- ujemnej dynamiki miesięcznej.

Jednocześnie wyraźne spowolnienie m/m sugeruje, że impuls wzrostowy został w dużej mierze skonsumowany.

5.5. Implikacje dla sektora bankowego

Z punktu widzenia banku oznacza to:

- Wzrost wartości zabezpieczeń - Wartość nieruchomości jako zabezpieczenia kredytów hipotecznych wzrosła o ponad 18%.
- Spadek ryzyka spadku cen w krótkim okresie - Prognoza nie wskazuje na odwrócenie trendu.
- Malejąca dynamika nowej akcji kredytowej (potencjalnie) - Spowolnienie cen może ograniczyć presję zakupową i spekulacyjną.
- Przejście do rynku bardziej selektywnego

W fazie spowolnienia większe znaczenie mają:

- lokalizacja,
- standard budynku,
- infrastruktura.

Czynniki jakościowe (centreDistance, buildYear, poiCount) mają silny wpływ na wycenę - co potwierdził model hedoniczny.

5.6. Podsumowanie rozdziału

- Ceny mieszkań w Warszawie wzrosły o 18,04% w ciągu 10 miesięcy.
- Dynamika miesięczna wyraźnie maleje.
- Model ARIMA wskazuje na dalszy, umiarkowany wzrost.
- Rynek znajduje się w fazie stabilizacji po silnej ekspansji.
- W krótkim okresie nie widać sygnałów gwałtownej korekty.

6. Analiza makroekonomiczna.

6.1. Dane makroekonomiczne.

W analizie uwzględniono trzy kluczowe wskaźniki makroekonomiczne:

- poziom inflacji,
- stopy procentowe,
- ceny paliw.

Dane obejmują okres od sierpnia 2023 do czerwca 2024 i zostały przekształcone do postaci zmian:

- miesięczna dynamika inflacji (inflation_mom),
- zmiana cen paliw (fuel_change),
- zmiana stóp procentowych (rate_change).

W celu uchwycenia opóźnionego wpływu czynników makroekonomicznych na rynek nieruchomości zastosowano również zmienne opóźnione (lagi).

6.2. Konstrukcja modelu makroekonomicznego.

Model został oszacowany w postaci regresji liniowej (OLS), gdzie zmienną objaśnianą był logarytm ceny za m² mieszkania.
Uwzględniono następujące zmienne:

- inflacja (opóźnienie 1 i 3 miesiące),
- zmiany stóp procentowych (bieżące i opóźnione),
- zmiany cen paliw,
- opóźnioną cenę mieszkań.

Model osiągnął współczynnik determinacji $R^2 = 0.034$ co wskazuje, że czynniki makroekonomiczne mają ograniczony, lecz istotny wpływ na ceny mieszkań.

6.3. Wyniki modelu

Najważniejsze wnioski:

- inflation_lag1 (-0.0605) - krótkookresowy wzrost inflacji wpływa negatywnie na ceny mieszkań
- rate_change (-0.0914) - wzrost stóp procentowych ogranicza popyt kredytowy
- rate_lag3 (+0.1269) - efekt stóp działa z opóźnieniem i może stabilizować rynek
- fuel_change (+0.0039) - wzrost cen paliw ma niewielki, ale istotny wpływ
- price_lag1 (+0.0120) - silna inercja cen (trend kontynuowany)

Wpływ makroekonomii jest opóźniony i relatywnie słabszy niż cechy nieruchomości

6.4. Scenariusz makroekonomiczny i prognoza

Na podstawie modelu zbudowano scenariusz bazowy uwzględniający:

- umiarkowaną inflację,
- stopniowy spadek stóp procentowych,
- stabilizację cen paliw.

Wpływ czynników makro został nałożony na prognozę ARIMA poprzez modelowanie odchyleń indeksu cen.

6.5. Wyniki prognozy

Wykres 6. Prognoza cen mieszkań vs scenariusze makroekonomiczne.

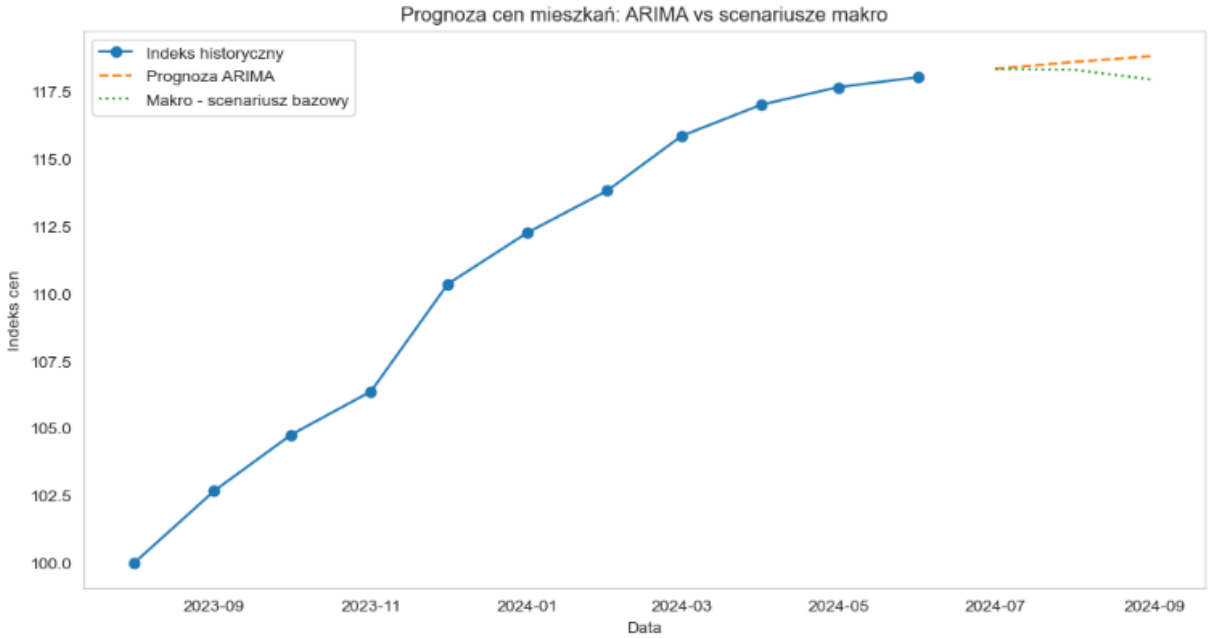

Na wykresie przedstawiono trzy kluczowe elementy analizy rynku nieruchomości: historyczny indeks cen mieszkań, prognozę uzyskaną na podstawie modelu ARIMA oraz prognozę skorygowaną o wpływ czynników makroekonomicznych. Zestawienie tych trzech ścieżek pozwala na ocenę zarówno kontynuacji trendu cenowego, jak i wpływu otoczenia makroekonomicznego na jego przebieg.

Analiza części historycznej wskazuje na wyraźny trend wzrostowy cen mieszkań, który w kolejnych miesiącach ulega stopniowemu wypłaszczeniu. Model ARIMA, bazujący wyłącznie na danych czasowych, prognozuje kontynuację tego trendu w sposób stabilny, bez gwałtownych zmian.
Uwzględnienie scenariusza makroekonomicznego prowadzi do niewielkiej korekty tej ścieżki. Prognoza skorygowana o czynniki makroekonomiczne przebiega nieco poniżej bazowej prognozy ARIMA, co oznacza, że wpływ otoczenia gospodarczego działa w kierunku lekkiego ograniczenia tempa wzrostu cen.
Najważniejszym wnioskiem z przeprowadzonej analizy jest to, że czynniki makroekonomiczne wpływają przede wszystkim na krótkookresową dynamikę cen mieszkań, nie zmieniając jednak zasadniczego, długookresowego trendu wzrostowego.
Z ekonomicznego punktu widzenia obserwowany efekt można interpretować jako wynik oddziaływania przeciwstawnych sił. Spadek stóp procentowych sprzyja wzrostowi cen mieszkań poprzez zwiększenie dostępności kredytów hipotecznych i wzrost popytu. Z kolei inflacja działa w kierunku przeciwnym, ograniczając realną siłę nabywczą gospodarstw domowych. Wypadkowa tych czynników prowadzi do lekkiego spowolnienia dynamiki wzrostu cen, co znajduje odzwierciedlenie w przebiegu scenariusza makroekonomicznego.

6.6. Wnioski

Model makroekonomiczny przyczynia się do zwiększenia realizmu prognozy cen mieszkań, ponieważ uwzględnia wpływ czynników zewnętrznych oddziałujących na rynek. Wpływ zmiennych makroekonomicznych jest istotny statystycznie, co potwierdza ich znaczenie w krótkookresowym kształtowaniu dynamiki cen. Jednocześnie ich oddziaływanie ma charakter ograniczony ekonomicznie, gdyż nie prowadzi do istotnych zmian długookresowego trendu.
Uwzględnienie czynników makroekonomicznych pozwala zatem na bardziej realistyczne modelowanie krótkookresowych wahań cen mieszkań, jednak główny trend cenowy pozostaje determinowany przez czynniki strukturalne rynku nieruchomości.

7. Analiza determinant cen mieszkań.

7.1. Cel i metodyka analizy

Celem analizy było określenie kluczowych czynników wpływających na poziom cen mieszkań na rynku w Warszawie. W tym celu zastosowano model uczenia maszynowego Random Forest, który pozwala uchwycić nieliniowe zależności pomiędzy cechami nieruchomości a ich ceną.

Do modelu wykorzystano następujące zmienne:

- powierzchnia mieszkania (squareMeters),
- liczba pokoi (rooms),

- piętro (floor),
- liczba pięter w budynku (floorCount),
- rok budowy (buildYear),
- odległość od centrum (centreDistance),
- liczba punktów usługowych w okolicy (poiCount).

Model został oszacowany na zbiorze treningowym (80% danych), a jego jakość oceniono na zbiorze testowym.

7.2. Jakość modelu

Model Random Forest osiągnął następujące wyniki:

- MAE ≈ 1736 zł/m²
- $R^2 \approx 0.67$

Oznacza to, że model wyjaśnia około 67% zmienności cen mieszkań, co wskazuje na dobre dopasowanie i wysoką zdolność predykcyjną, szczególnie jak na dane rynkowe o dużej heterogeniczności.

7.3. Znaczenie zmiennych

Wykres 7. Wykres hierarchii zmiennych.

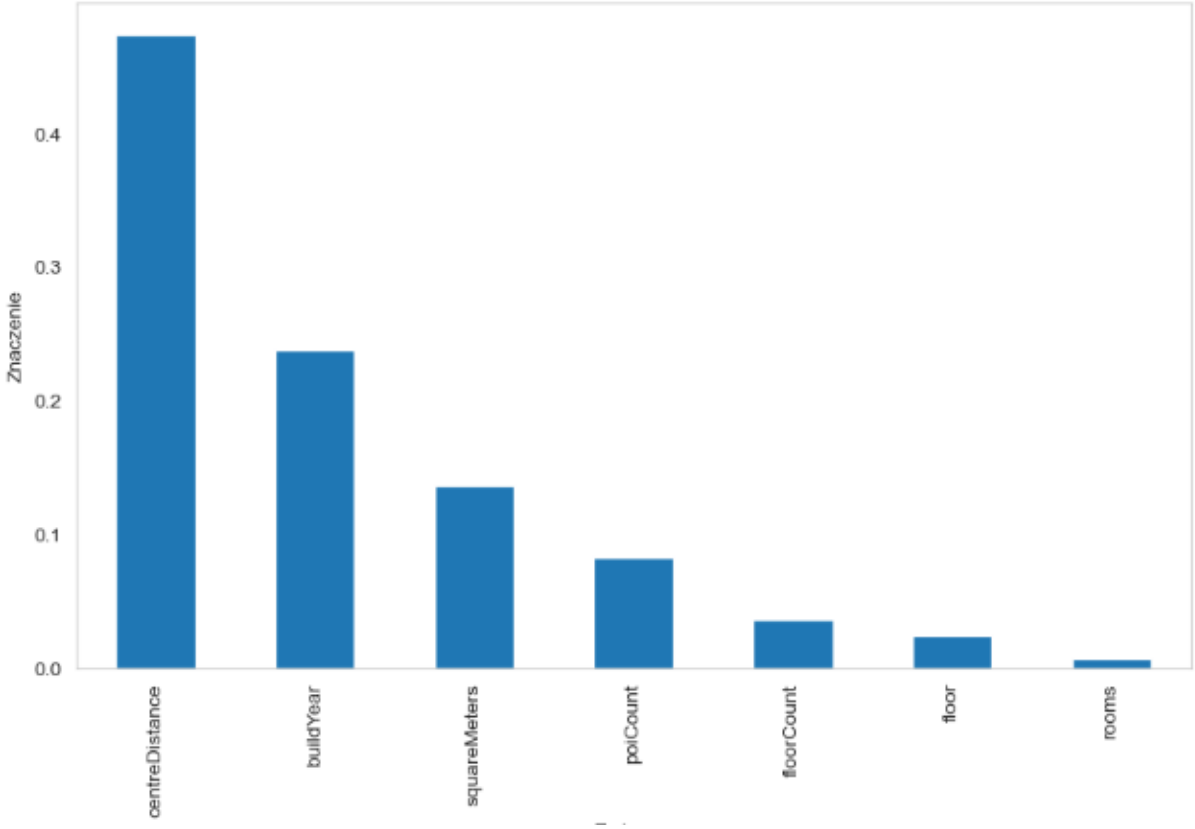

Wykres przedstawiający hierarchie zmiennych w modelu Random Forest wskazuje jednoznacznie, że najistotniejszym czynnikiem determinującym ceny mieszkań jest odległość od centrum (centreDistance), której znaczenie wyraźnie przewyższa pozostałe zmienne. Oznacza to, że lokalizacja stanowi kluczowy element kształtujący poziom cen. Drugą najważniejszą zmienną jest rok budowy (buildYear), co sugeruje, że nowsze budownictwo wiąże się z wyższymi cenami, prawdopodobnie ze względu na wyższy standard oraz lepszą efektywność energetyczną. Istotną, choć wyraźnie mniejszą rolę odgrywa także powierzchnia mieszkania (squareMeters), co wskazuje, że metraż wpływa na poziom ceny za metr kwadratowy, ale nie jest czynnikiem dominującym. Pozostałe zmienne, takie jak liczba punktów usługowych w okolicy, liczba pięter czy piętro, mają ograniczony wpływ na ceny. Szczególnie niską istotność wykazuje liczba pokoi, co sugeruje, że jej wpływ jest pośredni i wynika głównie z powiązania z metrażem mieszkania. Lokalizacja stanowi kluczowy czynnik kształtujący ceny mieszkań, co jest zgodne z klasyczną teorią ekonomii.

7.4. Zależności

Wykres 8. Zależności cząstkowe.

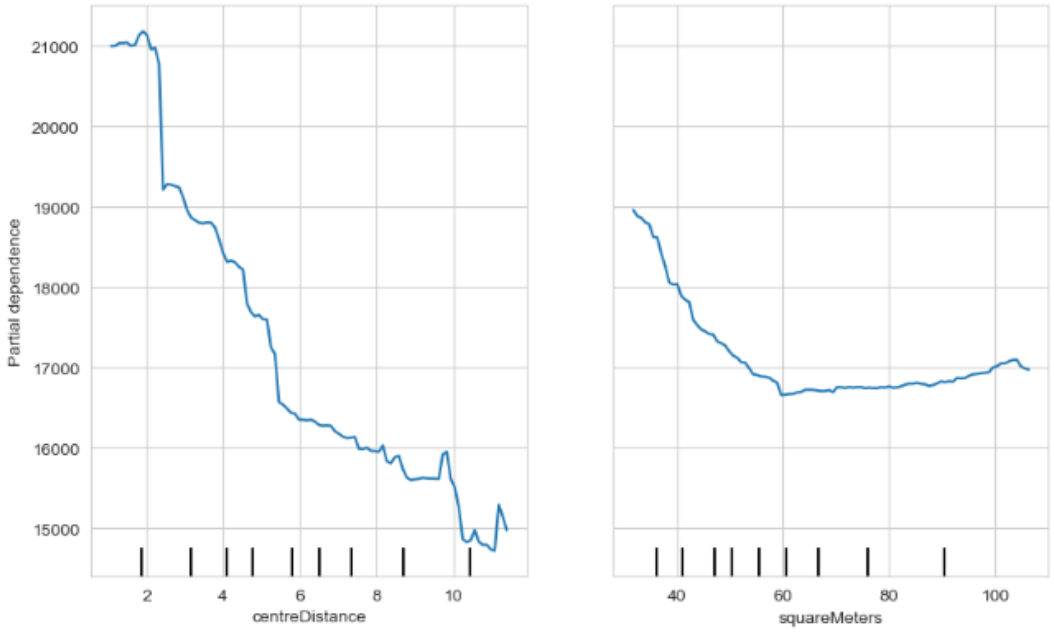

Wykresy zależności cząstkowych przedstawiają wpływ wybranych zmiennych na poziom cen mieszkań przy założeniu niezmienności pozostałych cech. W przypadku odległości od centrum (centreDistance) obserwowany jest wyraźny, nieliniowy spadek cen wraz ze wzrostem dystansu od centrum miasta. Najsilniejszy spadek występuje w początkowym zakresie odległości, co oznacza, że nawet niewielkie oddalenie od centrum prowadzi do istotnego obniżenia ceny. W dalszej odległości wpływ ten ulega stopniowemu wypłaszczeniu, co wskazuje na malejącą wrażliwość cen na kolejne zwiększanie dystansu.

Z kolei w przypadku powierzchni mieszkania (squareMeters) widoczna jest zależność, w której ceny za metr kwadratowy maleją wraz ze wzrostem metrażu, a następnie stabilizują się dla

większych mieszkań. Oznacza to, że mniejsze lokale osiągają wyższe ceny jednostkowe, natomiast większe mieszkania charakteryzują się niższą ceną za m², co jest typowym zjawiskiem na rynku nieruchomości.

7.5. Porównanie z modelem hedonicznym (OLS)

Porównanie wyników modelu Random Forest z klasycznym modelem regresji liniowej wskazuje na dużą zgodność w identyfikacji kluczowych czynników. W obu modelach dominującą rolę odgrywa lokalizacja, Random Forest wskazuje większe znaczenie metrażu, roku budowy, zmienna liczba pokoi traci znaczenie w modelu nieliniowym. Różnice pomiędzy modelami sugerują, że część zależności ma charakter nieliniowy i nie jest w pełni uchwycona przez model liniowy.

7.6. Wnioski

Przeprowadzona analiza wskazuje, że najważniejszym determinantem cen mieszkań jest lokalizacja, mierzona odległością od centrum miasta. Czynnik ten w sposób zdecydowany dominuje nad pozostałymi zmiennymi, co potwierdza kluczową rolę dostępności do infrastruktury miejskiej, miejsc pracy oraz usług w kształtowaniu wartości nieruchomości. Istotne znaczenie mają również cechy związane z jakością budynku, w szczególności jego wiek, który może być traktowany jako przybliżenie standardu technicznego oraz funkcjonalnego. Nowsze budynki zazwyczaj oferują wyższy standard, co przekłada się na wyższe ceny.
Powierzchnia mieszkania wpływa na poziom ceny w sposób nieliniowy, co oznacza, że zależność pomiędzy metrażem a ceną za metr kwadratowy nie jest proporcjonalna. W praktyce mniejsze mieszkania osiągają wyższe ceny jednostkowe, natomiast wraz ze wzrostem powierzchni cena za m² maleje i stabilizuje się. Z kolei liczba pokoi ma znaczenie wtórne, co sugeruje, że jej wpływ na cenę jest pośredni i w dużej mierze wynika z powiązania z metrażem nieruchomości.
Należy jednak podkreślić, że przeprowadzona analiza obarczona jest pewnymi ograniczeniami wynikającymi z dostępności danych. W szczególności brak szczegółowych informacji o lokalizacji, takich jak dzielnica czy konkretna ulica, ogranicza możliwość dokładnego uchwycenia zróżnicowania cen w obrębie miasta. Dodatkowo brak danych dotyczących standardu wykończenia mieszkań oraz stanu technicznego budynków powoduje, że istotne czynniki wpływające na wartość nieruchomości nie zostały bezpośrednio uwzględnione w modelu. Ograniczona liczba zmiennych opisujących otoczenie nieruchomości również wpływa na dokładność analizy.
W rezultacie ograniczona dostępność szczegółowych danych, w szczególności dotyczących lokalizacji oraz standardu nieruchomości, wpływa na zdolność modelu do pełnego wyjaśnienia zróżnicowania cen mieszkań. Część istotnych determinant pozostaje nieobserwowana, co może prowadzić do niedoszacowania rzeczywistego wpływu niektórych zmiennych oraz ograniczać precyzję wniosków.

8. Wnioski końcowe i rekomendacje

8.1. Podsumowanie wyników analizy

Celem analizy było oszacowanie trendu cen mieszkań w Warszawie z wykorzystaniem modelu hedonicznego oraz przygotowanie krótkookresowej prognozy.

Najważniejsze wyniki:

- Ceny mieszkań wzrosły o 18,04% w okresie sierpień 2023 - czerwiec 2024.
- Najsilniejszym determinantem ceny jest lokalizacja (odległość od centrum).

Rynek wyraźnie premiuje:

- nowe budownictwo,
- dobrą infrastrukturę lokalną.

Dynamika miesięczna wyraźnie spada - z ponad 3% m/m w grudniu 2023 do 0,31% m/m w czerwcu 2024.
Prognoza ARIMA wskazuje na dalszy, ale umiarkowany wzrost indeksu w III kwartale 2024.
Model jest stabilny statystycznie (niski condition number, brak autokorelacji reszt), co zwiększa wiarygodność wniosków.

8.2. Interpretacja sytuacji rynkowej

Analizowany okres można podzielić na dwa etapy:

- Faza silnej ekspansji (IV kwartał 2023)
  - gwałtowny wzrost cen,
  - wysoka dynamika miesięczna,
  - silny impuls popytowy.
- Faza normalizacji (I–II kwartał 2024)
  - stopniowe wygasanie dynamiki,
  - stabilizacja rynku,
  - brak oznak gwałtownej korekty.

Rynek nie wykazuje obecnie symptomów załamania, lecz przechodzi w bardziej zrównoważoną fazę cyklu.

8.3. Ryzyka dla rynku

Mimo braku sygnałów spadkowych w krótkim okresie, można wskazać kilka potencjalnych czynników ryzyka:

- spadek zdolności kredytowej gospodarstw domowych,
- pogorszenie koniunktury makroekonomicznej,
- ograniczenie dostępności finansowania hipotecznego,
- nadmierne wzrosty cen w wybranych segmentach premium.

Szczególnie istotne jest obserwowane wyraźne spowolnienie dynamiki miesięcznej - może ono oznaczać, że rynek osiąga punkt równowagi.

8.4. Implikacje dla banku

Z perspektywy instytucji finansowej wyniki analizy oznaczają:

- Stabilne zabezpieczenia kredytów - Wzrost cen zwiększa wartość zabezpieczeń hipotecznych.
- Niskie krótkookresowe ryzyko spadku cen - Prognoza nie wskazuje na odwrócenie trendu w najbliższych miesiącach.
- Większa selektywność segmentów - Model potwierdza, że ceny silnie zależą od:
  - lokalizacji,
  - roku budowy,
  - infrastruktury.

Oznacza to, że ryzyko kredytowe może być wyższe w peryferyjnych lokalizacjach oraz w starszym zasobie mieszkaniowym.

8.5. Ostateczna konkluzja

Rynek mieszkaniowy w Warszawie w analizowanym okresie charakteryzował się silnym wzrostem cen, który w pierwszej połowie 2024 roku wyraźnie wyhamował.
Nie obserwuje się oznak gwałtownej korekty, jednak dynamika wskazuje na przejście z fazy boomu do fazy stabilizacji.

Z punktu widzenia banku oznacza to:

- stabilne otoczenie cenowe w krótkim okresie,
- ograniczone ryzyko nagłego spadku wartości zabezpieczeń,
- konieczność selektywnej oceny ryzyka w zależności od lokalizacji i jakości nieruchomości.

Model hedoniczny oraz prognoza ARIMA dostarczają spójnego, ilościowego uzasadnienia tych wniosków.

8.6. Wnioski z analizy makroekonomicznej i czynników determinujących cenę

Przeprowadzona analiza potwierdza, że rynek mieszkaniowy charakteryzuje się względnie stabilnym, długookresowym trendem wzrostowym, który w niewielkim stopniu podlega wpływowi czynników makroekonomicznych. Model ARIMA wskazuje na kontynuację umiarkowanego wzrostu cen, natomiast uwzględnienie zmiennych makroekonomicznych pozwala uchwycić krótkookresowe odchylenia od tego trendu. W szczególności wzrost inflacji oraz stóp procentowych działa hamująco na dynamikę cen poprzez ograniczenie siły nabywczej i dostępności kredytu, podczas gdy ich spadek może wspierać popyt. Ostateczny efekt tych czynników ma jednak charakter korekcyjny - wpływa na tempo zmian, lecz nie zmienia zasadniczego kierunku rozwoju rynku.
Jednocześnie analiza determinant cen mieszkań wskazuje, że kluczową rolę w ich kształtowaniu odgrywają czynniki strukturalne, przede wszystkim lokalizacja oraz cechy jakościowe nieruchomości, takie jak wiek budynku czy metraż. Wyniki modeli, w tym Random Forest, potwierdzają istnienie nieliniowych zależności oraz dominujące znaczenie odległości od centrum. Należy jednak uwzględnić ograniczenia wynikające z dostępności danych, w szczególności brak szczegółowych informacji o lokalizacji i standardzie mieszkań, co może wpływać na precyzję oszacowań. Pomimo tych ograniczeń uzyskane wyniki dostarczają spójnego i wiarygodnego obrazu mechanizmów kształtujących ceny na rynku nieruchomości.

9. Opis wykonanych kroków i uzasadnienie metodologiczne

W niniejszym projekcie przeprowadzono pełny proces analizy danych - od ich wczytania i oczyszczenia, przez analizę eksploracyjną, po budowę modelu hedonicznego i prognozę szeregu czasowego.

9.1. Wczytanie i integracja danych

Dane były zapisane w osobnych plikach CSV dla każdego miesiąca, osobno dla rynku sprzedaży i najmu.

Zastosowano:

- automatyczne wyszukiwanie plików (glob),
- iteracyjne wczytywanie danych,
- wyodrębnienie roku i miesiąca z nazwy pliku,
- utworzenie zmiennej date (pierwszy dzień miesiąca),
- połączenie wszystkich miesięcy w jeden zbiór danych (pd.concat).

Uzasadnienie:
Takie podejście pozwala na:

- zachowanie informacji o czasie,
- łatwe rozszerzenie analizy o kolejne miesiące,

- budowę szeregu czasowego.

9.2. Wybór miasta - Warszawa

Dane zostały przefiltrowane do obserwacji dla miasta Warszawa.

Uzasadnienie:

- największa liczba obserwacji,
- najbardziej płynny rynek,
- największe znaczenie gospodarcze,
- większa stabilność estymacji modelu.

9.3. Ocena jakości danych

Przeprowadzono:

- analizę typów zmiennych,
- identyfikację braków danych,
- statystyki opisowe.

Zmiennych o dużej liczbie braków nie wykorzystano w modelowaniu.

Uzasadnienie:

- ograniczenie ryzyka błędów estymacji,
- poprawa stabilności modelu,
- uniknięcie silnego zmniejszenia próby po usunięciu braków.

9.4. Konstrukcja ceny za m²

Zdefiniowano zmienną:

$$price_per_m2 = \frac{price}{squareMeters}$$

Analogicznie dla rynku najmu.

Uzasadnienie:

- cena całkowita silnie zależy od wielkości mieszkania,
- cena za m² umożliwia porównywalność nieruchomości,
- jest standardową miarą w analizach rynku mieszkaniowego.

9.5. Czyszczenie danych

Zastosowano dwa filtry:

- Usunięcie mieszkań o powierzchni poniżej 15 m².
- Usunięcie obserwacji poniżej 1% i powyżej 99% rozkładu ceny za m².

Uzasadnienie:

- eliminacja błędów w danych,
- ograniczenie wpływu obserwacji ekstremalnych,
- poprawa jakości estymacji OLS.

9.6. Analiza trendów czasowych

Obliczono średnią cenę za m² w każdym miesiącu dla sprzedaży i najmu.

Wyznaczono:

- łączną zmianę procentową w okresie,
- relację czynsz/cena,
- prostą prognozę liniową trendu.

Uzasadnienie:

- pozwala zidentyfikować ogólną dynamikę rynku,
- umożliwia porównanie rynku sprzedaży i najmu,
- wskaźnik rent-to-price pozwala ocenić atrakcyjność inwestycyjną mieszkań.

Prosty model liniowy służył jako wstępne oszacowanie kierunku zmian.

9.7. Budowa modelu hedonicznego

9.7.1. Transformacja logarytmiczna

Zmienna zależna:

$$\text{log_price_m2} = \ln\,(price_per_m2)$$

Uzasadnienie:

- redukcja skośności rozkładu,
- stabilizacja wariancji,
- możliwość interpretacji parametrów jako przybliżonych zmian procentowych.

9.7.2. Wybór zmiennych objaśniających

Do modelu włączono:

- powierzchnię,
- liczbę pokoi,

- piętro,
- liczbę pięter,
- rok budowy,
- odległość od centrum,
- liczbę punktów usługowych.

Uzasadnienie:
Są to kluczowe determinanty ceny wynikające z teorii - cena nieruchomości jest funkcją jej cech użytkowych i lokalizacyjnych.

9.7.3. Zmienne czasowe (dummy months)

Utworzono zmienne zero-jedynkowe dla miesięcy.

Uzasadnienie:
- pozwala oddzielić zmianę jakości sprzedawanych mieszkań od rzeczywistego trendu cenowego,
- umożliwia budowę hedonicznego indeksu cen,
- eliminuje efekt zmiany struktury sprzedawanych mieszkań w czasie.

9.7.4. Standaryzacja zmiennych

Zmiennie ciągłe zostały przeskalowane przy użyciu StandardScaler.

Uzasadnienie:
- poprawa stabilności numerycznej,
- ograniczenie problemu współliniowości,
- obniżenie condition number,
- lepsza interpretacja względnej siły wpływu zmiennych.

9.7.5. Estymacja OLS

Model oszacowano przy użyciu statsmodels.OLS.
Wybrano OLS, ponieważ:
- umożliwia pełną diagnostykę modelu,
- pozwala na interpretację parametrów.

9.8. Konstrukcja hedonicznego indeksu cen

Na podstawie współczynników miesięcznych:

$$Index_t = 100 \times e^{\beta_t}$$

Sierpień 2023 przyjęto jako bazę (100).

Uzasadnienie:

- pozwala mierzyć czystą zmianę cen po kontrolowaniu jakości,
- eliminuje efekt zmiany struktury transakcji,
- umożliwia porównania międzyokresowe.

9.9. Prognozowanie - model ARIMA

Na logarytmie indeksu oszacowano model ARIMA(1,1,1).

Kroki:

- Logarytm indeksu.
- Różnicowanie (d=1).
- Estymacja parametrów.
- Prognoza 3 miesięcy.
- Transformacja odwrotna.

Uzasadnienie:

- ARIMA dobrze modeluje krótkookresową dynamikę szeregu czasowego,
- logarytm zapewnia stabilność wariancji,
- różnicowanie usuwa trend deterministyczny,
- model (1,1,1) jest elastyczny.

9.10. Dlaczego takie podejście jest właściwe?

Zastosowana metodologia łączy:

- Analizę przekrojową (model hedoniczny),
- Analizę szeregu czasowego (ARIMA),
- Czyszczenie i standaryzację danych,
- Kontrolę jakości sprzedawanych nieruchomości.

Takie podejście:

- minimalizuje ryzyko błędnej interpretacji trendów,
- oddziela efekt jakości od efektu czasu,
- umożliwia prognozowanie.

9.11. Walidacja modelu predykcyjnego

Walidacja modelu została przeprowadzona w celu oceny jego zdolności do uogólniania wyników na nowe, wcześniej niewidziane dane. Model hedoniczny został dopasowany na podstawie historycznych danych dotyczących transakcji mieszkań w Warszawie, jednak sama jakość dopasowania do danych treningowych (np. wysoki współczynnik R^2) nie gwarantuje, że model będzie równie dobrze przewidywał ceny dla nowych obserwacji.
Do oceny jakości predykcji wykorzystano miary błędu takie jak MAE (Mean Absolute Error), RMSE (Root Mean Squared Error) oraz współczynnik R^2. MAE informuje o średniej bezwzględnej różnicy między ceną rzeczywistą a przewidywaną przez model, natomiast RMSE silniej penalizuje większe błędy predykcji. Współczynnik R^2 wskazuje, jaka część zmienności cen mieszkań jest wyjaśniana przez zastosowany model.
Dodatkowo przeanalizowano wykres porównujący wartości rzeczywiste i przewidywane, który umożliwia wizualną ocenę jakości dopasowania modelu. Jeśli punkty na wykresie znajdują się blisko linii $y = x$, oznacza to, że model dobrze odwzorowuje rzeczywiste ceny mieszkań.
Przeprowadzenie walidacji jest istotnym elementem analizy, ponieważ pozwala ocenić wiarygodność modelu hedonicznego oraz jego przydatność do prognozowania cen mieszkań na rynku nieruchomości.

10. Walidacja modeli

W celu oceny wiarygodności zastosowanych modeli przeprowadzono walidację zarówno modelu hedonicznego, jak i modelu prognostycznego ARIMA. Analiza obejmowała ocenę jakości dopasowania modelu do danych historycznych oraz porównanie prognoz z rzeczywistymi obserwacjami.

10.1. Ocena jakości dopasowania modelu hedonicznego

Pierwszym krokiem walidacji była ocena dokładności predykcji modelu hedonicznego poprzez porównanie rzeczywistych cen mieszkań z wartościami przewidywanymi przez model. W tym celu obliczono dwa standardowe mierniki błędu prognozy:

- MAE (Mean Absolute Error) - średni błąd bezwzględny,
- RMSE (Root Mean Squared Error) - pierwiastek średniego błędu kwadratowego.

Wyniki walidacji przedstawiają się następująco:

- MAE = 2449,93 zł/m²
- RMSE = 3153,92 zł/m²

Oznacza to, że przeciętny błąd predykcji modelu wynosi około 2,45 tys. zł na metr kwadratowy, natomiast większe odchylenia od wartości rzeczywistych są silniej penalizowane w miarze RMSE. Biorąc pod uwagę średni poziom cen mieszkań w Warszawie w analizowanym okresie (około 17–18 tys. zł/m²), oznacza to względny błąd prognozy rzędu około 13–18%.
Wyniki te wskazują na umiarkowanie dobrą zdolność modelu do odtwarzania poziomu cen nieruchomości.

7.2. Analiza reszt modelu

Dodatkowo przeprowadzono analizę reszt modelu, czyli różnic pomiędzy wartościami rzeczywistymi a wartościami przewidywanymi przez model. Rozkład reszt jest zbliżony do rozkładu normalnego i skoncentrowany wokół wartości zerowej, co wskazuje na brak systematycznego przeszacowywania lub niedoszacowywania cen przez model.
Nie zaobserwowano również wyraźnych wzorców wskazujących na poważne problemy ze specyfikacją modelu. Oznacza to, że zastosowana forma logarytmiczna modelu hedonicznego jest odpowiednia dla analizowanych danych.

7.3. Walidacja prognozy indeksu cen

W celu oceny wiarygodności prognozy krótkookresowej zastosowano procedurę backtestu modelu ARIMA. Model został oszacowany na skróconym szeregu czasowym, a następnie wykorzystany do prognozy wartości indeksu dla ostatnich obserwacji.

Porównanie prognoz z rzeczywistymi wartościami indeksu przedstawia się następująco:

Miesiąc	Wartość rzeczywista	Prognoza
maj 2024	117,67	119,28
czerwiec 2024	118,04	121,58

Model nieznacznie przeszacowuje poziom indeksu cen, jednak zachowuje poprawny kierunek zmian oraz ogólną dynamikę wzrostową rynku. Różnice pomiędzy prognozą a wartościami rzeczywistymi mieszczą się w kilku punktach indeksowych, co jest akceptowalne przy krótkim szeregu czasowym.

7.4. Ocena ogólna wiarygodności modelu

Przeprowadzona walidacja wskazuje, że zastosowane modele posiadają wystarczającą zdolność do opisu dynamiki cen mieszkań w Warszawie. Model hedoniczny pozwala uchwycić wpływ najważniejszych cech nieruchomości na poziom cen, natomiast model ARIMA umożliwia krótkookresową prognozę trendu indeksu cen.
Należy jednak podkreślić, że dokładność prognoz jest ograniczona przez stosunkowo krótki okres obserwacji oraz ograniczoną liczbę zmiennych opisujących nieruchomości. W praktyce rynkowej dokładność modeli mogłaby zostać zwiększona poprzez wykorzystanie dłuższego szeregu czasowego oraz dodatkowych zmiennych lokalizacyjnych i jakościowych.